

SEMANTIČNA SEGMENTACIJA ZASNEŽENIH POVRŠIN V SLOVENIJI NA OSNOVI POSNETKOV SENTINEL-2

Domen Kavran¹, Mihaela Triglav Čekada², Niko Lukač³

DOI:

UDK:

IZVLEČEK

Semantična segmentacija zasneženih površin v Sloveniji na osnovi posnetkov Sentinel-2

V članku je obravnavana semantična segmentacija zasneženih površin v Sloveniji na osnovi multispektralnih satelitskih posnetkov Sentinel-2. Predlagana metoda semantične segmentacije temelji na uporabi modelov globokega učenja za generiranje binarne karte snega, pri čemer sta bili na lastni podatkovni zbirki 8300 območij preizkušeni arhitektura U-Net in temeljni model GASSL. Testiranje predlagane metode je bilo izvedeno na satelitskih posnetkih, ki prikazujejo Martuljske gore in Prisojnik, na katerih se nahajajo snežišča, ki vztrajajo čez celotno poletno sezono. Rezultati kažejo, da uporaba vseh 13 spektralnih slojev izboljša uspešnost semantične segmentacije, pri čemer je temeljni model GASSL dosegel najvišji povprečni presek nad unijo 0,4027.

KLJUČNE BESEDE: *semantična segmentacija, sneg, snežišče, Sentinel-2, globoko učenje, temeljni model*

ABSTRACT

Semantic Segmentation of Snowcovered Areas in Slovenia Based on Sentinel-2 Imagery

The paper focuses on semantic segmentation of snow-covered surfaces in Slovenia based on multispectral Sentinel-2 satellite imagery. The proposed semantic segmentation method relies on deep learning models to generate a binary snow map, with the U-Net architecture and the GASSL foundation model evaluated on a custom dataset covering 8,300 areas. The proposed method was tested on satellite imagery of the Martuljek and Prisojnik mountains, where permanent snowfields thrive through whole summer. The results show that using all 13 spectral bands improves semantic segmentation performance, with the GASSL foundation model achieving the highest mean Intersection Over Union (mIoU) of 0.4027.

KEYWORDS: *semantic segmentation, snow, snowfield, Sentinel-2, deep learning, foundation model*

¹ Fakulteta za elektrotehniko, računalništvo in informatiko, Univerza v Mariboru, (domen.kavran1@um.si, <https://orcid.org/0009-0001-4489-2085>)

² Geodetski inštitut Slovenije (mihaela.triglav@gis.si (<https://orcid.org/0000-0002-4200-2616>))

³ Fakulteta za elektrotehniko, računalništvo in informatiko, Univerza v Mariboru (niko.lukac@um.si (<https://orcid.org/0000-0002-9517-1157>))

1 Uvod

Spremljanje zasneženih površin nam nudi vpogled v spremembe podnebnih in vremenskih razmer. Obseg in trajanje zasneženih površin skozi leto sta tesno povezana z različnimi meteorološkimi parametri, kot so temperatura zraka, količina padavin in časovni razpored sneženja. Spremembe v zasneženosti vplivajo na vodni krog, kateri je odvisen od dinamike zadrževanja vode in njenega sproščanja v toplejšem delu leta. Zaradi tega je dolgoročen nadzor zasneženih površin ključen za razumevanje hidroloških procesov in ocenjevanje razpoložljivosti vodnih virov. Posebej izraziti in merljivi so ti procesi na gorskih območjih.

Snežišča in ledeniki so naravni pokazatelj spreminjanja dolgoročnih klimatskih parametrov, ki omogočajo tudi naključnemu opazovalcu, da s pomočjo ogleda njihove površine, ki jo primerja s površinami iz preteklih let, oceni kaj se v določenem letu dogaja s povprečnimi meteorološkimi parametri. Saj že površina snežišča ali ledenika, ki je v določenem trenutku pokrita s snežno odejo, lahko veliko pove o povprečni letni temperaturi (Triglav Čekada in Gabrovec 2013; Matko 2024; Triglav Čekada in Lamovec 2024; Vukalić in sod. 2026). Na obseg snega na ledenikih in snežiščih v določenem trenutku leta pa poleg meteoroloških parametrov vpliva tudi lokalna topografija terena. Natančna prepoznavna in spremljanje snega na zasneženih območjih, tudi izven območij ledenikov in snežišč, sta ključnega pomena tudi za razumevanje hidroloških procesov, saj snežna odeja pomembno vpliva na zadrževanje vode, časovni potek odtoka in razpoložljivost vodnih virov v toplejšem delu leta.

Poleg podrobnih fotogrametričnih spremljanj ledenikov in snežišč, ki omogočajo dolgoročne več desetletne študije spreminjanja ledenikov (na primer Triglav Čekada in sod. 2020) pa zadnjih nekaj desetletij za spremljanje zasneženih površin raziskovalci uporabljajo tudi različne satelitske sisteme (Triglav Čekada 2021). Če se osredotočimo samo na raziskave narejene s prosto dostopnimi satelitskimi podatki za območje Slovenije, pa velja omeniti test radarskega satelitskega sistema Sentinel-1 (Jesenko in sod. 2019). V tem članku se bomo osredotočili na multispektralni satelitski sistem Sentinel-2, ki je sestavljen iz dveh satelitov, ki posnameta površje Slovenije enkrat na približno 5 dni, in sicer v prostorski ločljivosti do 10×10 metrov na piksel. Takšni satelitski posnetki omogočajo učinkovito spremljanje rabe tal, vegetacije, vodnih površin in snežne odeje skozi čas. Zaradi proste dostopnosti in visoke prostorske ločljivosti podatke Sentinel-2 pogosto uporabljajo v različnih raziskavah, ki jih lahko združimo pod skupni imenovalec okoljskega spremljanja (Gorelick in sod. 2017). Podrobne analize spreminjanja obsega zasneženih območij znotraj posameznega leta, ki ga Sentinel-2 s svojo gosto časovno ločljivostjo omogoča, pa bodo lahko pripomogle tudi k podrobni analizi vpliva debeline snežne odeje na ohranjanje slovenskih snežišč.

Najnaprednejše tehnike za samodejno prepoznavo rabe tal, kamor štejemo tudi zasnežene površine, zajemajo metode s področja umetne inteligence, ki temeljijo

na globokih nevronske mrežah. Te arhitekture omogočajo samodejno učenje kompleksnih vzorcev iz večdimenzionalnih slikovnih podatkov. Najsodobnejše metode (angleško *state-of-the-art*) na področju modelov semantične segmentacije obsegajo:

- Konvolucijske nevronske mreže (angleško *Convolutional Neural Networks – CNNs*), ki za izračun značilk uporabljajo konvolucijske plasti (angleško *convolutional layers*). Prednost konvolucije je ta, da se z njeno pomočjo prepozna lokalne vzorce v vhodnih tenzorskih podatkih. Znanе arhitekture so U-Net (Ronneberger in sod. 2015), EfficientNetV2 (Tan in Le 2021), ShuffleNetV2 (Ma in sod. 2018) in ConvNeXtV2 (Woo in sod. 2023).
- Arhitekturo nevronske mreže Vision Transformer (ViT) (Kolesnikov in sod. 2021), ki združuje področje računalniškega vida z obdelavo naravnega jezika (angleško *Natural Language Processing – NLP*). Arhitektura ViT obravnava vhodno sliko kot zaporedje izrezkov slike, nad katerimi se nato uporabi tako imenovana večglava pozornost, ki dosega boljše razumevanje vzorcev v primerjavi z arhitekturami CNN. Uveljavljene arhitekture so EfficientViT (Cai in sod. 2023) in MaxViT (Tu in sod. 2022).
- Temeljne modele (angleško *Foundation Models*), ki so veliki, predhodno naučeni modeli za izvedbo različnih nalog. Individualen model se najprej naučeni delnih nalog, kot so na primer barvanje, rekonstruiranje in razlikovanje vhodnih posnetkov. Temu sledi učenje specializirane nadaljnje naloge, kot je na primer zaznavanje objektov in semantična segmentacija (Lu in sod. 2025). Individualen temeljni model večinoma vsebuje kodirnik oz. »hrbtenico« (angleško *backbone*), ki se nauči visokonivojskih predstavitev podatkov s pomočjo samonadzorovanega učenja. Za hrbtenico so lahko uporabljene poljubne arhitekture CNN in ViT. Znani temeljni modeli na področju daljinskega zaznavanja so TOV (Tao in sod. 2022), SeCo (Mañas in sod. 2021) in GASSL (Ayush in sod. 2021).

Cilj tega dela je bil razvoj metode semantične segmentacije na osnovi globokega učenja za prepoznavo zasneženih površin v multispektralnih posnetkih Sentinel-2. Pri tem smo uporabili najsodobnejše modele iz področja umetne inteligence. Predlagano metodo smo preizkusili na satelitskih podatkih, ki prikazujejo območji Martuljskih gora in Prisojnika, za katera že imamo prve fotogrametrične analize obnašanja snežišč, ki se nahajajo na njih. Namen analize je bilo ovrednotiti uporabnost metode za zaznavo zasneženih površin na območjih, kjer vemo, da se sneg ohrani tudi čez poletje.

V naslednjem poglavju predstavimo predlagano metodo semantične segmentacije zasneženih površin na satelitskih posnetkih. V tretjem poglavju je predstavljena priprava podatkovnih zbirk za učenje in testiranje predlagane metode ter rezultati eksperimentov. Delo povzamemo v zadnjem poglavju.

2 Predlagana metoda semantične segmentacije zasneženih površin

Postopek predlagane metode pričnemo s posredovanjem multispektralnega satelitskega posnetka v naučen model za izvedbo semantične segmentacije zasneženih površin. Vhodni multispektralni satelitski posnetek I velikosti $W \times H$, kjer W in H predstavljata širino in višino, lahko vsebuje poljubno število spektralnih slojev C . Njihovo število in zaporedje pa mora biti skladno s pričakovanji modela za semantično segmentacijo. Vhodni podatki so tako v obliki tridimenzionalnega tenzorja (angleško *tensor*).

Model (na primer globoka nevronska mreža) f_θ je naučen binarne semantične segmentacije zasneženih površin (0 – 'ni sneg', 1 – 'sneg') in nad vhomom I izračuna izhodno verjetnostno karto P , ki je enake velikosti kot I in vsebuje verjetnosti, da posamezen piksel pripada razredu 'sneg'. Končno segmentacijsko karto Y zasneženih površin se izračuna nad P z uporabo pragovne funkcije s pragom τ , ki je običajno nastavljen na 0,5. Opisan postopek je zapisan s spodnjo enačbo 1, kjer $Y_{i,j}$ predstavlja klasifikacijo piksla na lokaciji (i, j) glede na verjetnost $P_{i,j}$.

$$P = f_\theta(I), \quad I \in \mathbb{R}^{W \times H \times C}$$

$$Y_{i,j} = \begin{cases} 1, & \text{if } P_{i,j} \geq \tau & (\text{sneg}) \\ 0, & \text{if } P_{i,j} < \tau & (\text{ni snega}) \end{cases}$$

Enačba (1)

Za izvedbo semantične segmentacije se uporablja poljuben model globokega učenja, ki podpira izvedbo semantične segmentacije. To pomeni, da na vhod prejme dvodimenzionalno sliko s poljubnim številom spektralnih slojev, kar skupno predstavlja tridimenzionalni tenzor. Prav tako mora zadnja plast modela na izhodu vrniti dvodimenzionalni tenzor v enaki velikosti kot je vhodni tenzor. Če izhod ni enake velikosti, je to lahko narejeno z naknadnim povečanjem ali zmanjšanjem izhoda. Nad izhodnim tenzorjem je nato uporabljena sigmoidna funkcija (Sarker 2021), ki vse vrednosti preslika na razpon $[0, 1]$. Vrednosti v razponu $[0, 0,5]$ so prepoznane kot sneg, preostale pa ne.


3 Rezultati

Preizkušanje predlagane metode semantične segmentacije zasneženih površin smo izvedli z namenom ovrednotenja uspešnosti predlagane metode. Podatkovna zbirka z učno in testno množico, ki smo jo uporabili za eksperimente, je opisana v prvem podpoglavju. V drugem podpoglavju so opisane podrobnosti izvedbe eksperimentov, tretje podpoglavje pa vsebuje rezultate k-kratnega prečnega preverjanja, ki je bilo izvedeno z

namenom izbire spektralnih slojev za vključitev v vhodne satelitske posnetke. Zadnje podpoglavje zajema rezultate testiranja predlagane metode nad neodvisno testno množico in vizualizacijo napovedanih segmentacijskih kart zasneženih površin.

3.1 Podatkovna zbirka


Za izvedbo eksperimentov semantične segmentacije snega je bilo potrebno ustvariti učno in kontrolno množico, saj obširnih podatkovnih zbirk za prepoznavo snega nad podatki Sentinel-2 ni na voljo. Obe množici vsebujeta multispektralne posnetke Sentinel-2 s 13 spektralnimi kanali in pričakovane semantično označene slike s pripadajočimi Dynamic World oznakami (Brown in sod. 2022), katere zajemajo $N = 10$ semantičnih razredov rabe tal. Pridobivanje podatkov je bilo izvedeno z uporabo Google Earth Engine (GEE) (Gorelick in sod. 2017). Posnetki Sentinel-2 so bili pridobljeni iz harmonizirane podatkovne zbirke »COPERNICUS/S2_HARMONIZED«, ki zajema multispektralne satelitske posnetke Sentinel-2 (Level-1C) s 13 spektralnimi sloji odbojnosti na vrhu atmosfere (angleško *Top-of-Atmosphere – TOA*). Odločitev za uporabo TOA je bila sprejeta zaradi potencialnih izgub površinskih informacij ob uporabi površinske odbojnosti (angleško *surface reflectance*) pod samo atmosfero (angleško *Bottom-of-Atmosphere – BOA*) zaradi kompleksnosti korekcijskih postopkov. V ta namen smo ob pridobitvi posnetkov Sentinel-2 postavili omejitev, da ti lahko vsebujejo največ 5% oblačnost. Na osnovi



Slika 1: Primeri RGB posnetkov Sentinel-2 (a, b, c, d) s pripadajočimi binarnimi oznakami prisotnosti snega (e, f, g, h) v učni množici.

omejitvenih okvirjev so bile označene segmentacijske karte z Dynamic World oznakami pridobljene iz GEE podatkovne zbirke »GOOGLE/DYNAMICWORLD/V1«. Vsaka karta je bila nato binarizirana za prikaz snega, kjer vrednost 1 predstavlja prisotnost snega, 0 pa njegovo neprisotnost.


Za pripravo učne množice smo najprej ustvarili seznam 8300 naključnih lokacij na Zemeljskem površju. Za vsako lokacijo se je hranilo informacijo o območju, ki ga zajema (angleško *bounding box*), pri čemer so bila ta območja različnih velikosti. Podana sta bila tudi dva naključna datuma (od leta 2023 naprej), ki označujeta časovni obseg, znotraj katerega se nato najde razpoložljivi posnetek Sentinel-2 za to območje. Za vsako lokacijo se je nato z uporabo GEE pridobilo individualen multispektralni posnetek Sentinel-2 in pripadajočo segmentacijsko karto z Dynamic World oznakami v enakem prostorskem obsegu (Kavran in sod. 2026), kot ga prikazuje posnetek Sentinel-2. Temu je sledila



Slika 2: Posnetki Sentinel-2 za Martuljške gore (a, c, e, g) s pripadajočimi binarnimi oznakami prisotnosti snega (b, d, f, h) v kontrolni množici za 5. 7. 2015 (a, b), 24. 8. 2017 (c, d), 28. 7. 2020 (e, f) in 21. 8. 2023 (g, h).

izdelava binarne karte prisotnosti snega. Primeri posnetkov s pripadajočimi binarnimi kartami prisotnosti snega (sneg je označen z roza barvo) so prikazani na sliki 1.

Postopek priprave kontrolne množice, ki je nismo uporabili v postopku učenja modela semantične segmentacije, je skoraj enak postopku priprave učne množice. Edina razlika je ta, da so bila območja izbrana nad množico prostorsko umeščenih posnetkov, ki prikazujejo Martuljske gore (površina $6,16 \times 2,87$ km) in Prisojnik (površina $1,33 \times 0,93$ km), za katere vemo, da se na njih dolgo v poletje ohranijo snežišča. Za obe lokaciji so bili posnetki Sentinel-2 na voljo za leta 2017, 2020 in 2023, v letu 2015 pa zgolj za Martuljske gore. Kontrolna množica tako skupno vsebuje sedem posnetkov s pripadajočimi binarnimi kartami. Primeri teh posnetkov s pripadajočimi kartami prisotnosti snega (sneg je označen z belo barvo) so prikazani na sliki 2 in 3.



Slika 3: Posnetki Sentinel-2 za Prisojnik (a, c, e) s pripadajočimi binarnimi oznakami prisotnosti snega (b, d, f) v kontrolni množici za 6. 8. 2017 (a, b), 31. 7. 2020 (c, d) in 9. 9. 2023 (e, f).

3.2 Protokol eksperimentov

Ob preizkušanju predlagane metode semantične segmentacije smo uporabljali dva modela globokega učenja:

- Klasični U-Net (Ronneberger in sod. 2015) s kodirnikom ResNet-34 (He in sod. 2016).
- Manjši uveljavljen temeljni model GASSL (Ayush in sod. 2021) ob uporabi kodirnika ResNet-50 (He in sod. 2016). Uteži temeljnega modela so bile naučene nad podatkovno zbirko Functional Map of the World (FMoW) (Christie in sod. 2018). V repozitoriju kode (Ayush in sod. 2021) so bile te uteži na voljo za inicializacijo uteži tarčnega modela. Za segmentacijsko »glavo« (angleško *head*) smo uporabili arhitekturo UPerNet (Xiao in sod. 2018), saj se je ta izkazala za zelo kompatibilno pri izvedbi različnih nalog računalniškega vida, prav tako pa je bila zasnovana za uporabo značilk arhitekture ResNet.

Prav tako smo primerjali uporabo RGB kanalov in vseh 13 spektralnih slojev pri vhodnih posnetkih Sentinel-2. Najprej smo izvedli k-kratno prečno preverjanje (angleško *k-fold validation*), katerega rezultati so predstavljeni v naslednjem podpoglavju. Cilj k-kratnega prečnega preverjanja je najti optimalne parametre in hiperparametre ter preveriti, ali se sposobnost semantične segmentacije ustrezno prenaša iz učne množice na preostale podatke, ki niso bili uporabljeni pri učenju. V naših eksperimentih k-kratnega prečnega preverjanja je bil poudarek na tem, ali uporaba posnetkov z več spektralnimi sloji vodi v boljše rezultate semantične segmentacije kot uporaba zgolj navadnega RGB posnetka. Pri učenju smo uporabili v preglednici 1 zapisane hiperparametre in parametre učenja modelov.

Preglednica 1: Hiperparametri in parametri učenja modelov.

(Hiper)parameter	Izbira/opis
število zagonov ob izvedbi k-kratnega prečnega preverjanja	$k = 5$ (80% posnetkov učne množice za namen učenja vsakega od $k = 5$ modelov, preostanek pa kot validacijska množica za izvedbo validacije individualnega naučenega modela)
optimizacijski algoritem	AdamW (Loshchilov in Hutter 2017)
stopnja učenja	0,0006
velikost serije	8
izgubna funkcija	navzkrižna entropija (angl. Cross-Entropy) (Terven in sod. 2025)
število epoh učenja	25 za učenje modela U-Net in 35 za učenje modela GASSL (vrednosti so bile določene na podlagi preliminarних eksperimentov)

standardizirana velikost vhodnih posnetkov (izvedeno s predhodnim povečevanje/zmanjšanjem dimenzij posnetkov)	512 × 512 × pikslov ($C = 3$, če se uporablja RGB posnetke ali $C = 13$, če se uporablja vseh 13 spektralnih slojev)
velikost izhodne segmentacijske karte	1024 × 1024 (na enako velikost so se standardizirale tudi pričakovane binarne karte zasneženih površin za kasnejši izračun uspešnosti semantične segmentacije)
ob izvedbi k-kratnega prečnega preverjanja	0,5
ob izvedbi testiranja	0,01, 0,1, 0,25 in 0,5

V postopku učenja modelov smo uporabili tudi tehnike bogatenja slikovnih podatkov z namenom razširitve učne množice z dodatnimi, spremenjenimi satelitskimi posnetki. V ta namen se je izvajalo naključno horizontalno in vertikalno obračanje satelitskih posnetkov z verjetnostjo 50 %.

Ob izvedbi navzkrižne entropije se opazuje izguba (angleško *loss*) in rezultat izbrane metrike uspešnost semantične segmentacije. Pričakovano je, da izguba upada z večimi epohami učenja, uspešnost semantične segmentacije pa se povečuje in je zelo podobna med učno in validacijsko oz. kontrolno množico. V ta namen smo uporabili metriko preseka nad unijo (angleško *Intersection Over Union – IoU*), ki meri delež prekrivanja med napovedano in pričakovano semantično segmentacijo nekega razreda, s čimer se upošteva tudi prostorska porazdelitev (Terven in sod. 2025). Povprečenje IoU individualnih razredov (v našem primeru so to prisotnost in neprisotnost snega) vodi v izračun povprečnega preseka nad unijo (angleško *mean Intersection Over Union – mIoU*). Izračun metrike IoU je zapisan z enačbo 2, kjer GT_i in PR_i predstavljata pričakovano (tako imenovano »ground truth«) in napovedano (tako imenovano »predicted«) semantično segmentacijo za i -ti razred izmed vseh N razredov (Terven in sod. 2025). Končni izračun metrike mIoU je zapisan z enačbo 3.

$$IoU_i = \frac{|GT_i \cap PR_i|}{|GT_i \cup PR_i|} \quad \text{Enačba (2),}$$


$$mIoU = \sum_{i=1}^N IoU_i \quad \text{enačba (3).}$$

Po zaključenem k-kratnem prečnem preverjanju, s katerim smo izbrali najbolj primerne spektralne sloje v vhodnih satelitskih posnetkih, je sledila izvedba testiranja

predlagane metode. To je bilo izvedeno tako, da se je s celotno učno množico naučilo en sam model semantične segmentacije (to je U-Net ali GASSL), kateri je bil nato preizkušen pri različnih vrednostih τ znotraj pragovne funkcije za izračun napovedane binarne maske zasneženih površin.

3.3 Rezultati k-kratnega prečnega preverjanja

Rezultati k-kratnega prečnega preverjanja pri petih zaporednih zagonih so prikazani na sliki 4. Razvidno je, da je pri uporabi RGB kanalov potrebnih več epoch učenja, da dosežemo najvišjo možno uspešnost semantične segmentacije. To je v povprečju mIoU 0,8203 pri uporabi GASSL in 0,8304 pri uporabi nevronske mreže U-Net. Drugače pa je pri uporabi 13 spektralnih slojev v vhodnih posnetkih Sentinel-2, ki omogočijo konstantno doseganje višjih povprečnih mIoU že od prve epohe naprej. Dosegli so se tudi višji povprečni mIoU rezultati, in sicer do 0,8484 s temeljnim modelom GASSL in do 0,8471 z U-Net.



Slika 4: Rezultati metrike mIoU ob izvedbi k-kratnega prečnega preverjanja ($k = 5$) z obema preizkušenima modeloma globokega učenja. (a, b) Uporaba vseh 13 spektralnih slojev v vhodnih satelitskih posnetkih in (c, d) uporaba RGB kanalov v vhodnih satelitskih posnetkih.

Na sliki 4 so v vseh grafih vidna nihanja metrike mIoU. To je povsem normalno, prav tako pa je pričakovano, da se ta nihanja stabilizirajo skozi daljši čas učenja. To se je zgodilo, se pa je pojavila anomalija – peti validacijski zagon pri temeljnem modelu GASSL ob uporabi RGB kanalov (graf na sliki 4c) je dosegal nezadovoljive rezultate od 15 epohe dalje. Rezultati tega specifičnega zagona so bili izvzeti iz izračuna povprečja (črna črta).

3.4 Rezultati nad neodvisno kontrolno množico


V prejšnjem podpoglavju smo ugotovili, da najboljše rezultate dosežemo z uporabo vseh 13 spektralnih slojev v vhodnih posnetkih Sentinel-2. Za preizkus nad drugimi podatki oz. kontrolo predlagane metode smo naučili oba modela globokega učenja nad celotno učno množico, in ju testirali nad kontrolno množico s sedmimi satelitskimi posnetki, ki prikazujejo Martuljske gore in Prisojnik. Rezultati testiranja pri uporabi različnih vrednosti znotraj pragovne funkcije so zapisani v preglednici 2.

Najboljši rezultat mIoU smo pridobili s temeljnim modelom GASSL pri $\tau = 0,25$, in sicer 0,4027. U-Net je dosegel najboljši rezultat mIoU 0,3774 pri $\tau = 0,5$, kar je za -0,0253 slabše od najboljšega rezultata z GASSL. Tukaj je razlika med temeljnim modelom GASSL in U-Net veliko bolj očitna kot pri k-kratnem prečnem preverjanju, kjer so bila odstopanja manjša. V rezultatih preglednice 2 je prav tako lahko opazimo, da povečevanje τ nad 0,01 vodi v boljše rezultate, vendar od 0,25 naprej so pri modelu U-Net te izboljšave zelo majhne (+0,0009 pri $\tau = 0,5$), pri GASSL pa so rezultati celo slabši (-0,0014 pri $\tau = 0,5$).


Preglednica 2: Rezultati metrike mIoU ob izvedbi testiranja predlagane metode z obema preizkušeniima modeloma globokega učenja.

τ	Model globokega učenja	
	GASSL	U-Net
0,01	0,3230	0,3306
0,1	0,3945	0,3701
0,25	0,4027	0,3765
0,5	0,4013	0,3774

Rezultati semantične segmentacije zasneženih površin so prikazani na slikah 5 in 6, kjer se je za pridobitev napovedanih binarnih kart snega uporabilo naučen model GASSL pri najuspešnejši vrednosti $\tau = 0,25$. Razlike med pričakovanimi in napovedanimi



Slika 5: Pričakovane (a, b, c, d) in napovedane (e, f, g, h) segmentacijske karte zasneženih površin z označbo napačnih prepoznav (i, j, k, l) za Martuljške gore v kontrolni množici ob uporabi naučenega modela GASSL pri $\tau = 0,25$ za 5. 7. 2015 (a, e, i), 24. 8. 2017 (b, f, j), 28. 7. 2020 (c, g, k) in 21. 8. 2023 (d, h, l).



Slika 6: Pričakovane (a, b, c) in napovedane (d, e, f) segmentacijske karte zasneženih površin z označbo napačnih prepoznav (g, h, i) za Prisojnik v kontrolni množici ob uporabi naučenega modela GASSL pri $\tau = 0,25$ za 6. 8. 2017 (a, d, g), 31. 7. 2020 (b, e, h) in 9. 9. 2023 (c, f, i).

binarnimi kartami nakazujejo precenjevanja obsega snežne odeje, kar se odraža tudi v samem rezultatu metrike mIoU 0,4027. Na podlagi vizualnega pregleda rezultatov je bila predlagana metoda uspešnejša za posnetke, ki prikazujejo kontrolno območje Martuljskih gora, kot pa za območje Prisojnika.

4 Sklep

Predstavljeno delo obravnava semantično segmentacijo zasneženih površin v Sloveniji na osnovi posnetkov Sentinel-2. Osredotočili smo se na problem priprave podatkovne zbirke in na izbiro spektralnih slojev v uporabljenih satelitskih posnetkih.

Predstavljena metoda temelji na uporabi modela globokega učenja, ki sodi med najsodobnejše metode obdelave, za pridobitev binarne karte zasneženih površin na območju, ki ga predstavlja vhodni multispektralni satelitski posnetek. V ta namen smo najprej ustvarili lastno podatkovno zbirko posnetkov Sentinel-2 za 8300 območij na Zemeljskem površju. Podatkovno zbirko smo nato uporabili za izvedbo eksperimentov za preizkus uspešnosti predlagane metode semantične segmentacije snega. V ta namen smo preizkusili uporabo uveljavljene arhitekture globoke nevronske mreže U-Net in temeljnega modela GASSL.

Rezultati k-kratnega prečnega preverjanja so razkrili, da je višja uspešnost semantične segmentacije dosežena pri uporabi vseh 13 spektralnih slojev v primerjavi s slabšimi rezultati ob uporabi RGB kanalov. Pri testiranju predlagane metode v kontrolni množici, ki je obsegala posnetke Sentinel-2 za Martuljske gore in Prisojnik, smo dosegli najvišjo uspešnost semantične segmentacije mIoU 0,4027 s temeljnim modelom GASSL. Ta rezultat presega mIoU 0,3774, ki pa je bil dosežen z globoko nevronske mreže U-Net. Čeprav rezultati kažejo na precenjevanje obsega snežne odeje, predstavljena metoda vzpostavlja osnovni okvir za nadaljnji razvoj avtomatske semantične segmentacije snega. V prihodnosti bomo razširili podatkovno zbirko z dodatnimi satelitskimi posnetki, izvedli obširnejše eksperimente z dodatnimi temeljnimi modeli in preučili rezultate na večjem številu testnih območij.

ZAHVALA: Raziskovalno delo je bilo sofinancirano s strani Javne agencije za znanstvenoraziskovalno in inovacijsko dejavnost Republike Slovenije, v okviru temeljnega projekta št. J7-50095 in raziskovalnega programa št. P2-0041. Za posnetke Sentinel-2 se zahvaljujemo EU programu Copernicus.

5 Viri in literatura

- Ayush, K., Uz Kent, B., Meng, C., Tanmay, K., Burke, M., Lobell, D., Ermon, S. 2021: Geography-aware self-supervised learning. V: Conference Proceedings. 2021 IEEE/CVF International Conference on Computer Vision (ICCV). <https://doi.ieeecomputersociety.org/10.1109/ICCV48922.2021.01002>
- Ayush, K., Uz Kent, B., Meng, C., Tanmay, K., Burke, M., Lobell, D., Ermon, S. 2021: Geography-Aware Self-Supervised Learning 2021. *Programska koda*. SustainLab. <https://github.com/sustainlab-group/geography-aware-ssl>
- Brown, C. F., Brumby, S. P., Guzder-Williams, B., Birch, T., Hyde, S. B., Mazzariello, J. in sod. 2022: Dynamic World, Near real-time global 10 m land use land cover mapping. *Scientific Data* 9. <https://doi.org/10.1038/s41597-022-01307-4>
- Cai, H., Li, J., Hu, M., Gan, C., Han, S. 2023: EfficientViT: Lightweight Multi-Scale Attention for High-Resolution Dense Prediction. V: 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE. <https://doi.org/10.1109/ICCV51070.2023.01587>
- Christie, G., Fendley, N., Wilson, J., Mukherjee, R. 2018: Functional map of the World. V: 2018 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). IEEE. <https://doi.org/10.1109/CVPR.2018.00646>
- Gorelick, N., Hancher, M., Dixon, M., Ilyushchenko, S., Thau, D., Moore, R. 2017: Google Earth Engine: Planetary-scale geospatial analysis for everyone. *Remote Sensing of Environment* 202. <https://doi.org/10.1016/j.rse.2017.06.031>
- He, K., Zhang, X., Ren, S., Sun, J. 2016: Deep Residual Learning for Image Recognition. V: 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). IEEE. <https://doi.org/10.1109/CVPR.2016.90>
- Jesenko, D., Mongus, D., Shuang, L., Triglav Čekada, M. 2019: Detection of snow levels in the Slovenian Alps at different seasons using Sentinel 1. V: International Conference on Engineering, Science, and Industrial Applications (ICESI). IEEE. <https://doi.org/10.1109/ICESI.2019.8863012>
- Kavran, D., Triglav Čekada, M., Lukač, N. 2026: Global Sentinel-2 Snow Semantic Segmentation Dataset with Dynamic World Labels. *Podatkovna zbirka*. Univerza v Mariboru. <https://doi.org/10.5281/zenodo.19482842>.
- Kolesnikov, A., Dosovitskiy, A., Weissenborn, D., Heigold, G., Uszkoreit, J., Beyer, L., Minderer, M. in sod. 2021: An Image is worth 16×16 words: Transformers for image recognition at scale. V: Zbornik prispevkov mednarodne konference ICLR 2021. OpenReview. <https://doi.org/10.48550/arXiv.2010.11929>
- Loshchilov, I., Hutter, F. 2017: Decoupled weight decay regularization. V: International Conference on Learning Representations (ICLR 2017). ICLR. <https://doi.org/10.48550/arXiv.1711.05101>
- Lu, S., Guo, J., Zimmer-Dauphinee, J. R., Nieusma, J. M., Wang, X., VanValkenburgh, P., Wernke, S. A. in sod. 2025: Vision foundation models in remote sensing: A survey. *IEEE Geoscience and Remote Sensing Magazine* 13-3. <https://doi.org/10.48550/arXiv.2408.03464>
- Ma, N., Zhang, X., Zheng, H. T., Sun, J. 2018: ShuffleNet V2: Practical Guidelines for Efficient CNN Architecture Design. V: Computer Vision - ECCV 2018. ECCV. https://doi.org/10.1007/978-3-030-01264-9_8
- Mañas, O., Lacoste, A., Giró-i Nieto, X., Vazquez, D., Rodríguez, P. 2021: Seasonal Contrast: Unsupervised Pre-Training from Uncurated Remote Sensing Data. V: 2021 IEEE/CVF International Conference on Computer Vision (ICCV). IEEE. <https://doi.org/10.1109/ICCV48922.2021.00928>

- Matko, A. 2024: Preučevanje snežišč v Martuljskih gorah z interaktivno metodo orientacije posameznih fotografij. *Diplomsko delo*. Univerza v Ljubljani.
- Ronneberger, O., Fischer, P., Brox, T. 2015: U-Net: convolutional networks for biomedical image segmentation. V: *Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015*. Springer. https://doi.org/10.1007/978-3-319-24574-4_28
- Sarker, I. 2021: Deep Learning: A comprehensive overview on techniques, taxonomy, applications and research directions. *SN Computer Science* 2. <https://doi.org/10.1007/s42979-021-00815-1>
- Tan, M., Le, Q. V. 2021: EfficientNetV2: Smaller models and faster training. V: *International Conference on Machine Learning (ICML 2021)*. ICML. <https://doi.org/10.48550/arXiv.2104.00298>
- Tao, C., Qi, J., Zhang, G., Zhu, Q., Lu, W., Li, H. 2022: TOV: The Original Vision Model for optical remote sensing image understanding via self-supervised learning. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing* 16. <https://doi.org/10.48550/arXiv.2204.04716>
- Terven, J. R., Córdova-Esparza, D. M., Ramírez-Pedraza, A., Chavez-Urbiola, E. A., Romero-González, J. A. 2025: A comprehensive survey of loss functions and metrics in deep learning. *Artificial Intelligence Review* 58-7. <https://doi.org/10.48550/arXiv.2307.02694>
- Triglav Čekada, M., Gabrovec, M. 2013: Documentation of Triglav glacier, Slovenia, using non-metric panoramic images. *Annals of Glaciology* 54-62. <https://doi.org/10.3189/2013AoG62A095>
- Triglav Čekada, M. 2021: Izračun masnih bilanc ledenikov v času prosto dostopnih satelitskih podatkov. V: *Raziskave s področja geodezije in geofizike 2020: zbornik del: 26. srečanje Slovenskega združenja za geodezijo in geofiziko*. Slovensko združenje za geodezijo in geofiziko.
- Triglav Čekada, M., Radovan, D., Lipuš, B., Mongus, D. 2020: Very small glaciers as geoheritage: combining a spatio-temporal visualisation of their development and related effects of climate change. *Geoheritage* 12.
- Triglav Čekada, M., Lamovec, P. 2024: Snežišča okoli Prisojnika iz spletnih kamer. V: *Raziskave s področja geodezije in geofizike 2023: zbornik del: 29. srečanje Slovenskega združenja za geodezijo in geofiziko*. Slovensko združenje za geodezijo in geofiziko.
- Tu, Z., Talebi, H., Zhang, H., Yang, F., Milanfar, P., Bovik, A., Li, Y. 2022: MaxViT: Multi-axis vision transformer. V: *Computer Vision – ECCV 2022: 17th European Conference, Tel Aviv, Israel, October 23–27, 2022, Proceedings, Part XXIV*. Springer. <https://doi.org/10.48550/arXiv.2204.01697>
- Vukalić, A., Bončina, N., Skumavc, T., Triglav Čekada, M. 2026: Snežišča pod Prisojnikom in v Martuljski skupini iz fotografij in spletnih kamer. V: *Raziskave s področja geodezije in geofizike 2025: zbornik del: 31. srečanje Slovenskega združenja za geodezijo in geofiziko*. Slovensko združenje za geodezijo in geofiziko.
- Woo, S., Debnath, S., Hu, R., Chen, X., Liu, Z., Kweon, I. S., Xie, S. 2023: ConvNeXt V2: Co-designing and scaling ConvNets with masked autoencoders. V: *2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE. <https://doi.org/10.48550/arXiv.2301.00808>
- Xiao, T., Liu, Y., Zhou, B., Jiang, Y., Sun, J. 2018: Unified perceptual parsing for scene understanding. V: *Computer Vision – ECCV 2018: 15th European Conference. ECCV*. <https://doi.org/10.48550/arXiv.1807.10221>
- Yin, J., Dong, J., Hamm, N. A. S., Li, Z., Wang, J., Xing, H., Fu, P. 2021: Integrating remote sensing and geospatial big data for urban land use mapping: A review. *International Journal of Applied Earth Observation and Geoinformation* 103. <https://doi.org/10.1016/j.jag.2021.102514>